



计算机应用
Journal of Computer Applications
ISSN 1001-9081, CN 51-1307/TP

《计算机应用》网络首发论文

题目：融合用户历史行为与社交关系的个性化社交事件推荐方法
作者：孙鹤立，徐统，何亮，贾晓琳
收稿日期：2020-05-19
网络首发日期：2020-09-16
引用格式：孙鹤立，徐统，何亮，贾晓琳. 融合用户历史行为与社交关系的个性化社交事件推荐方法[J/OL]. 计算机应用.
<https://kns.cnki.net/kcms/detail/51.1307.TP.20200915.1450.002.html>



网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

融合用户历史行为与社交关系的个性化社交事件推荐方法

孙鹤立, 徐统, 何亮, 贾晓琳*

(西安交通大学 电子与信息学部, 西安 710049)

(*通信作者电子邮箱 xlinjia@xjtu.edu.cn)

摘要: 随着移动互联网的发展, 基于事件的社交网络(EBSNs)已经被许多研究者深入研究。基于事件的社交网络中的用户之间不仅可以通过在线社交平台提供的服务进行在线互动, 而且可以面对面的参加离线社交活动。在基于事件的社交网络快速发展的同时也出现了许多问题, 其中社交事件推荐问题受到了广泛的关注。为了提升基于事件社交网络中社交事件的推荐效果, 提出了融合用户历史行为和社交关系的个性化社交事件推荐方法。该方法采用深度学习技术从用户的历史行为以及用户之间的潜在社交关系两个方面建立用户模型。在对用户偏好建模时, 引入用户偏好的负向量表示, 并使用注意力权重层根据不同的候选推荐事件为用户历史行为中不同的事件和用户社交关系中不同的好友分配不同的权重, 同时考虑了事件以及群组的多种特征。最后在真实数据集上进行了大量实验, 实验结果表明, 该个性化社交事件推荐方法在 HR@K、NDCG@K 以及 MRR 评价指标上相对于深度用户社交事件推荐方法(DUMER)提升了 8% 左右。

关键词: 基于事件的社交网络; 深度学习; 个性化推荐方法; 注意力机制; 用户建模

中图分类号: TP311

文献标志码: A

Personalized social event recommendation method integrating user historical behavior and social relationship

SUN Heli, XU Tong, HE Liang, JIA Xiaolin*

(Department of Electronics and Information, Xi'an Jiaotong University, Xi'an Shaanxi 710049, China)

Abstract: With the development of mobile Internet, Event-based Social Networks (EBSNs) was studied by many researchers. Users in Event-based Social Networks can not only interact online through the services provided by online social platforms, but also participate in social activities face to face. As the rapid development of event-based social networks, many problems were emerged. Among them, the recommendation of social events was received extensive attention. In order to improve the recommendation effect of social events based on event social networks, a personalized social event recommendation method combining historical behaviors and social relationships of users was proposed. The method uses deep learning technology to build a user model from two aspects: the user's historical behavior and the potential social relationship between users. When modeling user preferences, the negative vector representation of user preferences was introduced, and the attention weight layer was used to assign different weights to different events in the user's historical behavior and different friends in the user's social relationship according to different candidate recommendation events, and considered the various characteristics of events and groups. Finally, a lot of experiments were carried out on the real data set. The experimental results show that the personalized social event recommendation method has an 8% promotion in the HR@K, NDCG@K, and MRR(Mean Reciprocal Rank) evaluation indicators relative to the Deep User Modeling framework for Event Recommendation (DUMER) algorithm.

Keywords: Event-Based Social Networks (EBSN); deep learning; personalized recommendation method; attention mechanism; user modeling

0 引言

随着移动互联网的发展, 各种社交服务平台大量涌现, 其中基于事件的社交网络(Event-based Social Networks, EBSNs)受到越来越多的关注, 如 Meetup、Eventbrite、豆

收稿日期: 2020-05-19; 修回日期: 2020-07-20; 录用日期: 2020-07-22。

基金项目: 国家自然科学基金资助项目(61672417)。

作者简介: 孙鹤立(1983—), 女, 辽宁铁岭人, 副教授, 博士, CCF 会员, 主要研究方向: 数据挖掘、复杂网络分析; 徐统(1994—), 男, 河南许昌人, 硕士研究生, 主要研究方向: 社交网络、深度学习; 何亮(1975—), 男, 陕西西安人, 讲师, 博士, CCF 会员, 主要研究方向: 数据挖掘、机器学习; 贾晓琳(1963—), 女, 陕西西安人, 高级工程师, 博士, CCF 会员, 主要研究方向: 数据挖掘、机器学习。

瓣同城等。基于事件的社交网络的快速发展,吸引了众多科研工作者对其进行研究。Liu 等^[1]在 2012 年首次给出了基于事件社交网络的定义。此后研究者们对基于事件的社交网络进行了广泛研究,提出了许多新的研究问题,如事件的流行因素发现^[2]、事件的联合搭档推荐^[3]、事件的参与人数预测^[4]、群组的流行度预测^[5]、线上线下的社交影响^[6]等问题。基于事件社交网络中的用户之间不仅可以进行在线社交互动,也可以参加线下事件进行离线社交互动。随着基于事件社交网络中事件数量的增多,导致了平台中用户事件信息过载的问题。为了减轻信息过载带来的消极影响,各个基于事件的社交网络服务平台都推出了自己的解决方法,目前比较普遍的解决办法是为每个用户推荐其所在城市的事件,同时允许用户搜索事件。由于用户在参加线下事件时不仅要考虑对该事件的兴趣,同时也要考虑该事件举办的时间和地点等其它影响因素,所以仅根据用户所在城市推荐事件的方法不能够为用户提供满意的推荐结果,而用户根据平台预先设定条件搜索事件的方法则灵活性不足,因此基于事件社交网络中的个性化社交事件推荐问题引起了研究者的广泛关注。

在基于图模型的推荐方法中,研究者们通常将社交网络构建为一个图模型,将推荐问题转换为结点之间的接近度问题,图模型选择与查询结点之间转移概率较大的结点构成查询结点的推荐结果列表。Pham 等^[7]提出了基于异构图的推荐算法(HeteRS),该算法将社交网络建模为异构网络来获取社交网络中语义信息进行推荐。Liu 等^[8]将社交网络构建为图模型,然后执行随机游走算法并从用户参加过的活动中提取用户偏好,得到最终的推荐事件列表。Mo 等^[9]将社交网络构建为异构网络,并使用逆向随机游走算法进行推荐。Liu 等^[10]在研究连续事件推荐时分别将社交网络构建为主图和反馈图,然后再图上执行随机游走算法进行社交事件推荐。

在基于影响因素的推荐方法中,研究者在推荐过程中综合考虑多种因素来提升推荐效果。任星怡等人^[11]在研究社交网络中的兴趣点推荐时,综合考虑了地理位置、社交等因素;Macedo A Q 等^[12]在事件的推荐过程中考虑了待推荐事件的上下文信息、事件的地理位置信息以及用户的地理位置信息来提升推荐效果。Qiao Z 等^[13]综合考虑了用户的线上和线下社交关系、事件的地理位置和用户的隐性评分等因素来进行事件推荐。Liao G 等^[14]首先构建事件参与网络和物理邻近网络两个异构网络。然后使用它们来提取用户的潜在偏好和潜在社交关系等重要因素。

近年来,深度学习技术的发展为解决基于事件社交网络中的推荐问题提供了新的解决思路。Shan Y 等^[15]2016 年提出的 Deep Crossing 模型是使用深度学习技术决推荐问题的经典方法。该模型通过加入嵌入层(Embedding Layer)将稀疏特征转化为低维稠密特征,然后将分段的特征向量连接起来,再通过多层残差网络完成特征的组合、

转换,然后进行推荐。Cheng H T 等人^[16]提出了 Wide&Deep 模型,该模型 Wide 部分和 Deep 部分分别具有记忆能力和泛化能力。Song W 等人^[17]则使用 Transformer 网络中的多头自注意力机制(Multi-head Self-attention Mechanism)^[18]来学习不同特征的权重提出了自动特征交互模型(AutoInt)。Zhou 等^[19]提出了融合注意力机制的深度兴趣网络(Deep Interest Network, DIN)模型,该模型从用户的历史行为中提取用户特征,然后使用激活单元使模型能够根据不同候选物品调整用户历史行为中不同物品的权重。Wang 等^[20]使用 TextCNN 方法从用户历史参与的事件中提取用户偏好提出了深度用户事件推荐模型(Deep User Modeling framework for Event Recommendation, DUMER)。

本文使用深度学习方法,同时结合基于事件社交网络的特点,从用户历史行为中提取用户偏好,使用注意力机制根据候选推荐事件自动学习与用户关联的历史社交事件的权重。本文在建立用户模型时,引入表示用户偏好的负向量,并从用户的社交网络中提取用户的社交关系向量。此外,在推荐过程中考虑了事件的时间地点信息以及用户兴趣爱好随时间变化等影响因素。在真实数据集上的实验结果表明,文章所提出的提出深度用户偏好和社交关系模型(Deep User Preference and Social Relationship Model, DUPSRM)在多个评价指标上优于当前的算法。

1 基于事件的社交网络

基于事件的社交网络模型如图 1 所示,主要包含用户、群组和事件三种实体,用户之间存在线上社交互动和线下社交互动。




图 1 基于事件的社交网络

Fig.1 Event-based social networks

给定基于事件的社交网络 $SN = \{V, R\}$, V 表示其中的实体集合, R 表示关系集合。 $V = \{U, G, E\}$, 其中 U 为用户集合, G 表示群组集合, E 表示离线事件集合。 $R = \{R^{on}, R^{off}\}$ 表示用户之间的关系集合, R^{on} 表示用户之间的在线社交关系, R^{off} 表示用户之间的离线社交关系。

本文将基于事件的社交网络中的社交事件推荐问题转化为目标用户是否会参加候选推荐事件的二分类问题。对于目标用户 u , $E_p^u = \{e_{p1}, e_{p2}, \dots, e_{pk}\}$ 表示用户 u 参与的事件序列, $E_n^u = \{e_{n1}, e_{n2}, \dots, e_{nm}\}$ 表示用户 u 拒绝参与的事件序列。

列, $N_u = \{n_1, n_2, \dots, n_z\}$ 表示以用户 u 为中心的在线社交网络和离线社交网络中的社交邻居集合, e 表示候选推荐事件。社交事件推荐问题可以描述如下: 对于目标用户 u , 候选推荐事件 e , 目标用户 u 的参与事件序列 E_p^u 和拒绝参与事件序列 E_n^u , 以及用户的社交邻居集合 N_u , 判断目标用户 u 是否会参与候选事件 e 。

2 深度用户偏好和社交关系模型

本文在对用户建模时, 考虑了用户的历史行为特征以及用户的潜在社交关系; 在对社交事件建模时, 考虑了事件所在群组的类别特征、事件的地理位置特征和事件的时间段特征, 提出 DUPSRM 模型, 图 2 展示了该模型的结构。

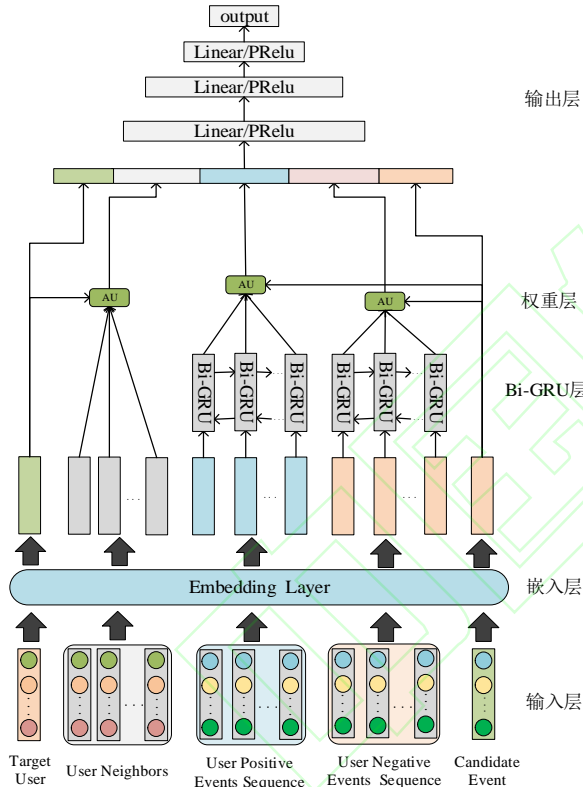


图 2 DUPSRM 模型结构图

Fig. 2 DUPSRM Architecture

该模型主要由输入层、嵌入层、双向门循环单元层 (Bidirectional Gated Recurrent Unit Layer, Bi-GRU Layer)、权重层以及输出层组成, 下面对该模型进行详细的介绍。

2.1 输入层

输入层接收输入数据, 输入数据主要包含用户数据和候选推荐事件数据两个部分, 其中用户数据部分主要包含了目标用户、目标用户社交邻居集合, 以及目标用户历史行为相关的数据。因此, 输入数据中主要包含了用户和社交事件这两种实体, 这两种实体由多个特征域组成, 下面分别描述这两种实体的数据输入形式。

用户实体的数据包含了用户 id、地理位置区块、兴趣类别这 3 个特征域; 社交事件实体的数据来自事件 id、事件群组 id、事件地理位置、事件类别、时间段这 5 个特征域, 这些特征域中的特征为离散特征, 因此需要对离散特征进行独热编码后从输入层输入模型, 图 3 表示了用户实体和社交事件实体的独热编码向量。

User :	(0,0,0,0,1,...,0,0)(0,0,1,...,0,0)(0,0,1,...,0,0)				
	User id	Location	Category		
Event :	(0,0,0,0,1,...,0,0)(0,0,0,0,1,...,0,0)(0,0,1,...,0,0)(0,0,1,...,0,0)(0,0,1,...,0,0)				
	Event id	Group id	Location	Category	TimeSlot

图 3 实体的独热编码向量

Fig3. The one-hot vector of entity

在划分地理位置区块时, 统计用户与其所参与的事件经纬度之间的距离, 来确定大部分用户经常参与社交事件的地理范围, 图 4 为用户与参加事件之间距离的累积分布图。




图 4 用户参与事件之间距离的累积分布图

Fig4. User event distance CDF

从用户事件距离累积分布图中可以发现, 有 83% 的用户活动在 4km 的范围内, 因此将纽约市划分为 80 个 4km*4km 的地理区块, 使用用户所处的区块来代替用户的地理位置信息。

2.2 嵌入层

输入层的离散特征经过独热编码后特征维度升高, 同时变得十分稀疏, 在模型的训练过程中, 特征过于稀疏则会导致整个网络收敛速度过慢, 因此需要将输入层的数据输入嵌入层, 将特征域的独热编码向量转化为低维稠密向量。

Embedding 起源于词向量 Word2Vec 模型, 在多个深度学习领域中, 如以推荐、广告、搜索为核心的互联网领域, Embedding 技术被广泛地应用, 因此 Embedding 技术是深度学习中的基础操作。Embedding 通常由浅层神经网络实现。

对于输入层中的用户实体和社交事件实体包含了多个特征域, 经过嵌入层后每个特征域映射为低维稠密特征向量, 然后将不同特征域的嵌入向量进行拼接, 就得到了实体的低维嵌入特征向量表示, 用户实体的嵌入向量为:

$$uemb = \text{concat}(uid_emb, loc_emb, cate_emb) \quad (1)$$

社交事件实体的嵌入向量为:

$$eveemb = \text{concat}(eid_emb, gid_emb, loc_emb, cate_emb, ts_emb) \quad (2)$$

其中, $\text{concat}(\mathbf{g})$ 表示拼接函数。

2.3 双向 GRU 层

循环神经网络是一类用于处理序列数据的神经网络。在 DUPSIRM 模型中将用户历史参与事件和拒绝参与事件按照时间顺序排列, 生成用户的历史事件序列, 然后使用双向 GRU 层来从用户的历史事件序列中提取社交事件之间的关联, 双向 GRU 层中包含了两层传递方向相反的 GRU 层, 每层中包含了多个 GRU 单元, 用来获取从前向后和从后向前的序列信息, 设每层 GRU 层中包含了 k 个 GRU 单元, 在从前向后的 GRU 层中, \mathbf{h}_i 表示该层中第 i 个 GRU 单元的隐状态, \mathbf{h}_i 包含了既包含了前面 $(i-1)$ 个隐状态中的特征, 也包含了第 i 个事件的特征; 在从后向前的 GRU 层中, \mathbf{h}_{k-i+1} 表示该层中第 $(k-i+1)$ 个 GRU 单元的隐状态, \mathbf{h}_{k-i+1} 既包含了后面 $k-i$ 个隐状态中的特征, 也包含了第 $(k-i+1)$ 个事件的特征, 然后将 \mathbf{h}_i 和 \mathbf{h}_{k-i+1} 对应元素求和, 便得到表示第 i 个事件的向量 $\mathbf{h}_i = \mathbf{h}_i \mathring{+} \mathbf{h}_{k-i+1}$, 该向量中既包含了事件 i 的特征也包含了事件序列中与事件 i 相邻的事件的特征。

2.4 权重层

在 DUPSIRM 模型中权重层的权重激活单元使用了 DIN 模型^[18]中的结构, 用来计算用户历史参与事件序列 \mathbf{E}_p^n 中的事件和拒绝参与事件序列 \mathbf{E}_n^n 中的事件对用户参与候选推荐事件 \mathbf{e} 的影响权重, 权重激活单元的结构如图 5 所示。




图 5 权重激活单元

Fig.5 Weight Activation Unit

下面以双向 GRU 层的隐向量 \mathbf{h}_i 为例介绍权重激活单元的作用。

权重激活层中的激活单元(AU)计算过程如下:

$$AW_{h_i} = f([\mathbf{h}_i, \mathbf{h}_i \mathbf{e} \mathbf{e}, \mathbf{e}]) \quad (3)$$

$$W_{h_i} = \frac{\exp(AW_{h_i})}{\mathring{\sum}_{j=1}^o \exp(AW_{h_j})} \quad (4)$$

$$\mathbf{V}_u = \mathring{\sum}_{j=1}^o W_{h_j} * \mathbf{h}_j \quad (5)$$

其中, $f(\mathbf{g})$ 表示激活单元中的线性层和激活层, $[\mathbf{gg}]$ 表示向量拼接, \mathbf{e} 表示向量点积, AW_{h_i} 表示候选事件为 \mathbf{e} 时, 隐向量 \mathbf{h}_i 的权重, W_{h_i} 表示隐向量 \mathbf{h}_i 的归一化权重, 当 $\mathbf{e}_i \hat{=} \mathbf{E}_u^p$ 时, \mathbf{V}_u 表示目标用户 u 历史事件的正向量 $\mathbf{V}_u^{\text{positive}}$, 当 $\mathbf{e}_i \hat{=} \mathbf{E}_u^n$ 时, \mathbf{V}_u 表示目标用户历史事件的负向量表示 $\mathbf{V}_u^{\text{negative}}$ 。

在计算用户的社交邻居向量时, 计算方法如下:

$$AW_{h_i} = f([\mathbf{u}_i, \mathbf{u}_i \mathbf{e} \mathbf{e}, \mathbf{e}]) \quad (6)$$

$$W_{u_i} = \frac{\exp(AW_{u_i})}{\mathring{\sum}_{j=1}^o \exp(AW_{u_j})} \quad (7)$$

$$\mathbf{V}_u^{\text{neighbor}} = \mathring{\sum}_{j=1}^o W_{u_j} * \mathbf{u}_j \quad (8)$$

经过权重层后, 就获得了目标用户 u 完整的向量表示:

$$\mathbf{V}_u = \text{concat}(\mathbf{V}_u^{\text{emb}}, \mathbf{V}_u^{\text{neighbor}}, \mathbf{V}_u^{\text{positive}}, \mathbf{V}_u^{\text{negative}}) \quad (9)$$

2.5 输出层

经过双向 GRU 层和权重层后得到了用户的完整向量表示 \mathbf{V}_u 和候选事件 \mathbf{e} 的向量表示, 由于矩阵分解算法的前提假设是用户隐向量 \mathbf{V}_u 和候选事件隐向量 \mathbf{e} 来自共同的 k 维隐向量空间, 在 DUPSIRM 模型中由于用户向量 \mathbf{V}_u 和候选事件向量 \mathbf{e} 的特征维度不同, 因此将用户向量 \mathbf{V}_u 和候选事件向量 \mathbf{e} 拼接起来, 输入到多层感知机中预测目标用户 u 参与候选事件 \mathbf{e} 的概率, 输出层的计算过程如下:

$$\hat{y} = \mathbf{s}(f[\mathbf{V}_u, \mathbf{e}]) \quad (10)$$

其中, $f(\mathbf{g})$ 表示输出层的多层感知机, $[\mathbf{gg}]$ 表示向量拼接, $\mathbf{s}(\mathbf{g})$ 表示 sigmoid 激活函数。

在 3.1 小节, 将个性化社交事件推荐问题转化为目标用户 u 是否参与候选推荐事件 \mathbf{e} 的二分类问题, 因此 DUPSIRM 模型的损失函数采用对数损失函数:

$$L = - \frac{1}{N} \mathring{\sum}_{y \in S} [y \log(\hat{y}) + (1-y) \log(1-\hat{y})] + \frac{\lambda}{2} \| \mathbf{w} \|^2 \quad (11)$$

其中: S 表示训练集, N 为训练集样本数量, y 表示样本标签, \hat{y} 表示模型的预测输出。 λ 表示 L2 正则化系数, \mathbf{w} 表示网络参数。

3 实验结果与分析

3.1 数据集

在实验过程中使用 Meetup 网站提供的 API 对纽约市的数据进行爬取,对数据进行清洗和一系列预处理操作后得到实验数据集,该数据集包含了纽约市的社交群组、用户以及线下社交事件,数据集的具体信息如表 1 所示。为了保证同一个用户出现在训练集和测试集中,数据集划分采用 Top-K 推荐中常用的留一法。测试集中的负样本采用随机抽样生成。

表 1 Meetup 数据集信息

Tab.1 Meetup dataset information

实体	数量
用户	7248
群组	925
事件	14202

3.2 对比算法

- (1) DUMER 模型:该模型使用 TextCNN 方法从用户参与的历史事件内容中提取用户偏好的向量表示,然后将用户的向量表示与候选推荐事件的向量表示使用概率矩阵分解方法进行事件推荐。
- (2) DIN 模型:使用用户的历史行为信息对其建模,通过激活单元对于不同的候选事件自动学习用户历史参与事件的权重以获得用户的向量表示,然后将用户向量和候选事件向量输入多层神经网络,由神经网络输出最终的推荐概率。
- (3) DUPM 模型:为了验证本文提出的 DUPSRM 模型的中引入用户偏好负向量表示带来的效果,该模型在推荐时只考虑用户的偏好。
- (4) DUSRM 模型:为了验证本文提出的 DUPSRM 模型的中引入用户社交关系带来的效果,在推荐时只考虑用户的偏好正向量表示和用户的社交关系。

3.3 评价指标

在推荐系统中,HR、NDCG、MRR (Mean Reciprocal Rank) 等指标经常被用来评价模型或算法的效果,本文也使用以上三个指标对模型进行评估:

(1) HR@K 用来衡量模型的召回率,在 K 确定的情况下,HR 取值越大,表明模型的召回率越高,HR@K 的计算方式如下:

$$HR @ K = \frac{NumberofHits @ K}{|GT|} \quad (12)$$

其分母表示测试集中样本总数,分子表示每个用户推荐列表的前 K 个项目中属于测试集中个数的总和。

(2) NDCG@K 用来对推荐列表中每个项目的预测概率值排序,如果推荐列表中靠前项目的预测概率值越大,则 NDCG 的值越大,模型的推荐效果越好。

$$NDCG @ K = \frac{\hat{a}_{u|U} NDCG_u @ K}{|U|} \quad (13)$$

其分母表示测试集中用户的数量,分子为每个用户的 NDCG 值之和。

(3) MRR 是正确检索结果值在检索结果中的排名来评估检索系统的性能,其计算方法如下:

$$MRR = \frac{1}{|U|} \hat{a}_{u|U} \frac{1}{rank_i} \quad (14)$$

其中,|U| 是用户的个数,rank_i 表示对于第 i 个用户,推荐列表中第一个相关物品所在的排列位置。

3.4 对比与分析

(1) HR@K 结果对比

图 6 为五种模型在数据集上 HR@K 的运行结果的柱状图。从图中可以看出,五种模型在 HR@10 评价指标下的 HR 值均优于 HR@5 评价指标下的 HR 值,说明随着推荐事件数量的增加,五种模型的推荐效果都会有提升。而 DUPM 模型、DUSRM 模型以及 DUPSRM 模型在数据集上的表现好于 DUMER 模型和 DIN 模型,说明这三个模型能够为推荐较多与用户相关联的社交事件。DUPSRM 模型相对于 DUMER 模型在 HR@5 指标下提升了 3 个百分点,在 HR@10 指标下提升了 7.6%。五种模型中,DUMER 模型的 HR 值最低,说明在推荐过程中仅使用社交事件的描述信息不能为用户推荐合适的社交事件。DUPM 模型和 DUSRM 模型的 HR 值较为接近,说明用户的社交关系和用户偏好负向量在社交事件推荐过程中都能带来推荐效果的提升。




图 6 HR@K 实验结果

Fig.6 The experiment result of HR@K

(2) NDCG@K 结果对比

如图 7 所示,在 NDCG@5 和 NDCG@10 评价指标下,DUPM 模型、DUSRM 模型以及 DUPSRM 模型在数据集上的表现均好于 DUMER 模型和 DIN 模型,说明这三个模型能够将与目标用户相关联的事件排序在推荐列表中靠前的位置,推荐的效果更好。DUPSRM 模型相对于 DUMER 模型在 NDCG@5 指标下提升了 1.6 个百分点,在 NDCG@10 指标

下提升了 8.1%。而 DUMER 模型在五个模型中表现最差，DIN 模型表现相对较好。DUPM 模型和 DUSRM 模型的 NDCG 值相对于 DUMER 模型和 DIN 模型都有提升，五种模型中 DUSRM 模型的 NDCG 值最高，说明该模型的推荐效果最好。




图 7 NDCG@K 实验结果

Fig.7 The experiment result of NDCG@K

(3) MRR 结果对比

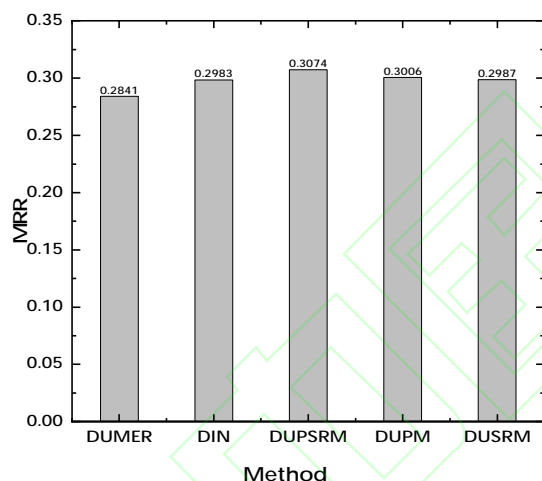


图 8 MRR 实验结果

Fig.8 The experiment result of MRR

图 8 为五种模型在数据集上 MRR 的运行结果柱状图，从图中可以看出五种模型在 MRR 评价指标下的差异。在 MRR 评价指标下，在数据集上五种模型中 DUMER 模型的 MRR 值最低，DIN 模型的 MRR 值次之，DIN 模型的推荐效果好于 DUMER 模型。DUSRM 模型的推荐效果相对于 DUMER 模型在 MRR 指标下提升了 8.2%，DUPM 模型的推荐效果略好于 DUSRM 的效果。

4 结语

本文使用深度学习方法来解决基于事件社交网络中个性化社交事件推荐问题，在推荐过程中使用社交邻居信息以及历史行为信息对用户建模。在使用用户历史行为信息建模时，

构建了用户偏好的正向量及负向量。使用双向 GRU 层和权重层建立用户的向量表示，提高了模型的准确性。通过在真实数据集上的实验结果表明，本文提出的 DUSRM 模型的效果相比于当前基于事件社交网络中的个性化社交事件推荐方法有一定的提升。同时，基于事件社交网络中离线事件也包含了许多上下文特征，如事件的规模、事件的组织者信息等，这些特征可能对于用户参与事件有一定的影响，这也为我们改进 DUSRM 模型或者提出新模型指明了方向。

参考文献

- [1] LIU X, HE Q, TIAN Y, et al. Event-based social networks: linking the online and offline social worlds[C]// Proceedings of the 18th ACM SIGKDD International Conference on Knowledge discovery and data mining. New York: ACM, 2012: 1032-1040.
- [2] ZHANG S, LV Q. Event organization 101: Understanding latent factors of event popularity[C]// Proceedings of the 11th International AAAI Conference on Web and Social Media. Montreal: AAAI, 2017: 716-719.
- [3] YIN H, ZOU L, NGUYEN Q V H, et al. Joint event-partner recommendation in event-based social networks[C]// Proceedings of the 2018 IEEE 34th International Conference on Data Engineering (ICDE). Piscataway: IEEE, 2018:929-940.
- [4] DU R, YU Z, MEI T, et al. Predicting activity attendance in event-based social networks: Content, context and social influence[C]// Proceedings of the 2014 ACM International Joint Conference on Pervasive and Ubiquitous Computing. New York: ACM, 2014: 425-434.
- [5] PRAMANIK S, GUNDAPUNENI M, PATHAK S, et al. Can i foresee the success of my meetup group?[C]// Proceedings of the 2016 IEEE/ACM International Conference on Advances in Social Networks Analysis and Mining (ASONAM). Piscataway: IEEE, 2016: 366-373.
- [6] 杜蓉, 於志文, 刘振鲁, 等. 基于豆瓣同城活动的线上线下社交影响研究[J]. 计算机学报, 2014, 37(1):238-245. (Du R, Yu Z W, Liu Z L. Research on online and offline social influence based on Douban event[J]. Chinese Journal of Computers, 2014, 37(1):238-245.)
- [7] PHAM T A N, LI X, CONG G, et al. A general graph-based model for recommendation in event-based social networks[C]// Proceedings of the 2015 IEEE 31st International Conference on Data Engineering. Piscataway: IEEE, 2015: 567-578.
- [8] LIU S, WANG B, XU M. Event recommendation based on graph random walking and history preference reranking[C]// Proceedings of the 40th International ACM SIGIR Conference on Research and Development in Information Retrieval. New York: ACM, 2017: 861-864.
- [9] MO Y, LI B, WANG B, et al. Event recommendation in social networks based on reverse random walk and

- participant scale control[J]. Future Generation Computer Systems, 2018, 79: 383-395.
- [10] LIU S, WANG B, XU M. Serge: Successive event recommendation based on graph entropy for event-based social networks[J]. IEEE Access, 2017, 6: 3020-3030.
- [11] 任星怡, 宋美娜, 宋俊德. 基于位置社交网络的上下文感知的兴趣点推荐[J]. 计算机学报, 2017, 40(4):824-841.(REN X Y, SONG M N, SONG J D. Context-aware interest point recommendation based on location social network[J]. Chinese Journal of Computers, 2017, 40(4):824-841.)
- [12] MACEDO A Q, MARINHO L B, SANTOS R L T. Context-aware event recommendation in event-based social networks[C]// Proceedings of the 9th ACM Conference on Recommender Systems. New York: ACM, 2015: 123-130.
- [13] QIAO Z, ZHANG P, CAO Y, et al. Combining heterogenous social and geographical information for event recommendation[C]// Proceedings of the 28th AAAI Conference on Artificial Intelligence. New York: ACM, 2014: 145-151.
- [14] LIAO G, ZHAO Y, XIE S, et al. An effective latent networks fusion based model for event recommendation in offline ephemeral social networks[C]// Proceedings of the 22nd ACM international conference on Information & Knowledge Management. New York: ACM, 2013: 1655-1660.
- [15] SHAN Y, HOENS T R, Jiao J, et al. Deep crossing: Web-scale modeling without manually crafted combinatorial features[C]// Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. New York: ACM, 2016: 255-262.
- [16] CHENG H T, KOC L, HARMSSEN J, et al. Wide & deep learning for recommender systems[C]// Proceedings of the 1st workshop on deep learning for recommender systems. New York: ACM, 2016: 7-10.
- [17] SONG W, SHI C, XIAO Z, et al. AutoInt: Automatic feature interaction learning via self-attentive neural networks[C]// Proceedings of the 28th ACM International Conference on Information and Knowledge Management. New York: ACM, 2019: 1161-1170.
- [18] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need[C]// Advances in neural information processing systems. Long Beach: NIPS, 2017: 5998-6008.
- [19] ZHOU G, ZHU X, SONG C, et al. Deep interest network for click-through rate prediction[C]// Proceedings of the 24th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining. New York: ACM, 2018: 1059-1068.
- [20] WANG Z, ZHANG Y, CHEN H, et al. Deep user modeling for content-based event recommendation in event-based social networks[C]// Proceedings of the 2018 IEEE Conference on Computer Communications. Piscataway: IEEE, 2018: 1304-1312.

This work is partially supported by the National Science Foundation of China(61672417).

SUN Heli, born in 1983, Ph.D., associate professor. Her research interests include data minning, complex network analysis.

XU Tong, born in 1994, M.S. candidate. His research interests include social network, deep learning.

HE Liang, born in 1975, Ph.D., lecturer. His research interests include data minning, machine learning.

JIA Xiaolin, born in 1963, Ph.D., senior engineer. Her research interests include data minning, machine learning.